

Determinação de áreas potencialmente afetadas em caso de acidente com transporte ferroviário de mercadorias perigosas

Relatório técnico — análise estatística e mapeamento de risco

Desafio LX Data Lab · 0125

Promotor: Serviço Municipal de Proteção Civil de Lisboa (SMPC)

Pipeline reprodutível: `analise/desafio.py`

Dados originais: amostras fornecidas pelo SMPC (1998–2002, 100 viagens · 2 555 registos de matérias)

Versão 2 · normalização ADR/RID · parser Kemler pior caso · índice de risco composto · 9 mapas de calor

Autor

Valter Micas

26 de maio de 2026

Índice

1. Sumário executivo	3
2. Metodologia	4
2.1 Fontes de dados	4
2.2 Limpeza e normalização	4
2.3 Parser de pior caso — código Kemler	5
2.4 Índice de risco composto	6
3. Resultados das análises pedidas	6
3.1 Matérias por classe ADR/RID	6
3.2 Viagens por dia da semana	7
3.3 Distribuição horária	8
3.4 Top 10 — por frequência	8
3.5 Top 10 — por risco (pior caso)	9
4. Mapas de calor	10
4.1 Janela temporal — Dia × Hora	10
4.2 Severidade — Classe × N° Perigo	11
4.3 Matriz de fluxo — Origem × Destino	12
4.4 Perfil de risco normalizado — Top 15	13
4.5 Correlações entre indicadores	14
4.6 Mapa de impacto espacial — pior caso	15
4.7 Painel de impacto — Top 10	16
5. Corredor Parque das Nações ↔ Alcântara	17
6. Conclusões e recomendações	19
Anexo — Ficheiros gerados	20

1. Sumário executivo

Este estudo caracteriza o risco do transporte ferroviário de matérias perigosas com paragem no corredor Parque das Nações ↔ Alcântara, em Lisboa, com base nas duas amostras disponibilizadas pelo SMPC: o registo de viagens (100 viagens entre 1998-06-29 e 2002-03-28) e o registo detalhado das matérias transportadas (2 555 linhas, 1 701 IDs distintos).

O pipeline aplicou limpeza exaustiva (detectando que 81 % das linhas tinham o N° Perigo indevidamente colocado na coluna Classe), normalizou as classes contra o conjunto ADR/RID válido, implementou um parser que devolve sempre o pior cenário para o código Kemler, e calculou um índice de risco composto por linha. Foram produzidos 4 gráficos clássicos e 9 mapas de calor, incluindo a simulação espacial 2D do impacto de um acidente.

Indicador	Valor
Viagens (amostra de transportes)	100
Viagens com paragem em Alcântara	98
Linhas de matérias	2 555
IDs distintos no registo de matérias	1 701
Produtos canónicos distintos (após dedupe)	186
Classes ADR/RID distintas (após normalização)	13
Quantidade total movimentada (kg)	39 421 454
Classe dominante	3 — Líquidos inflamáveis
Raio de evacuação máximo registado (m)	1 600
Índice de risco máximo (escala 0–1)	0.803
Índice de risco médio (escala 0–1)	0.539
Linhas com Kemler intensificado (dígito duplo)	1 065
Linhas com prefixo X (reage com água)	2

Conclusão operacional: o corredor concentra 100 % dos transportes da amostra numa janela noturna estreita (19h–23h, dias úteis), atravessa zonas de densidade urbana muito alta (Entrecampos, Sete Rios, Roma–Areeiro) e impõe um buffer de planeamento de **800 m** para os 10 produtos mais frequentes, com extensão a **1 600 m** no cenário extremo de gases liquefeitos sob pressão.

2. Metodologia

2.1 Fontes de dados

Ficheiro	Linhas	Período/IDs	Conteúdo
Amostra_Registo do Transporte Ferroviário...xlsx	100	1998-06-29 → 2002-03-28	Uma linha por viagem (data, hora, origem, destino, qtd total)
Amostra_Registo das matérias transportadas.xlsx	2555	1 701 IDs distintos a partir do ID 1646	Detalhe por produto (ONU, classe, Kemler, raios, explosão)

Nota crítica de integridade: os ID das duas amostras não se sobrepõem (transportes 0001-0060; matérias 1646+). Como 98 % das viagens da amostra de transportes têm paragem em Alcântara, a amostra de matérias é tratada como representativa do universo "viagens com paragem em Alcântara".

2.2 Limpeza e normalização

Operação	Coluna(s)	Resultado
Strip + colapso de espaços + remoção de chars zero-width	todas string	aplicado a 100 % das linhas
Conversão para datetime/time	DATA, HORA PARTIDA, HORA CHEGADA	0 erros de parsing
Validação de Nº ONU (inteiro de 4 dígitos)	Nº ONU	1 inválido (mantido e sinalizado)
Normalização de CLASSE contra conjunto ADR/RID válido	CLASSE	2 074 / 2 555 corrigidas (81 %) — Kemler na coluna Classe
Forma canónica de produto (sem acentos, lowercase)	TIPO PRODUTO	186 produtos canónicos a partir de 240+ variantes
Conversão numérica forçada com tracking de NaN	quantidades e raios	NaN preservados, sem imputação
Normalização de origem/destino (acentos)	ORIGEM, DESTINO	Alcantara = Alcântara

Cada linha tem agora colunas auditáveis: ONU_NORM, ONU_LIMPEZA, CLASSE_NORM, CLASSE_LIMPEZA, PRODUTO_CANON. Tabelas limpas em `analise/clean/`.

2.3 Parser de pior caso — código Kemler (Nº Perigo)

O algarismo da placa cor-de-laranja do RID codifica a natureza do perigo. O algoritmo implementado satisfaz o requisito de **cenário menos favorável**:

- Faz *split* por ou / or / / / , / + para obter alternativas.
- Detecta prefixo X (reage perigosamente com água).
- Detecta dígitos duplicados (intensificação — ex.: 33, 66, 88).
- Ordena por severidade decrescente: X > sem X > mais dígitos > intensificado > valor numérico maior.
- Devolve o código vencedor + descrição textual dos riscos.

Dígito Kemler	Significado
2	Gás sob pressão / emissão por reação química
3	Inflamabilidade (líquido / gás / autoaquecimento)
4	Inflamabilidade de sólido
5	Comburente
6	Toxicidade / infeção
7	Radioatividade
8	Corrosividade

Dígito Kemler	Significado
9	Reação espontânea violenta
0	Sem perigo secundário
duplicado (33, 66...)	Risco intensificado
Prefixo X	Reage perigosamente com água

Verificação:

- "30 ou 33" → escolhido **33** (inflamabilidade intensificada). ✓
- "60 ou 66" → escolhido **66** (toxicidade intensificada). ✓
- "X462" (Fosforeto de alumínio) → mantém o X → severidade máxima. ✓

Total na amostra: **1 065 registos com Kemler intensificado** (41,7 %) e **2 com prefixo X**.

2.4 Índice de risco composto

Para cada linha foi calculado um índice de risco normalizado em [0, 1]:

```
risco_indice = 0.40 · severidade_kemler_norm  
              + 0.30 · log10(quantidade_kg)_norm  
              + 0.20 · raio_evac_norm  
              + 0.10 · risco_explosão (0/1)
```

onde `severidade_kemler` = nº de dígitos não-zero distintos do código pior caso + 1,5 (se X) + 0,5 (se intensificado). A quantidade é tomada em escala logarítmica para evitar saturação por outliers. Os pesos são transparentes e configuráveis no script.

3. Resultados das análises pedidas pelo desafio

3.1 Identificação das matérias por classe ADR/RID

Após normalização (recuperando ~81 % das linhas que tinham o campo CLASSE ocupado com o Nº Perigo):

Classe	Nº reg.	Viagens	Quantidade (kg)	Risco médio	Risco máx.	% reg.
3 — Líquidos inflamáveis	1120	788	12 704 403	0.57	0.77	43.80
2 — Gases	407	383	6 512 654	0.55	0.80	15.90
8 — Matérias corrosivas	329	278	5 423 869	0.53	0.76	12.90
6.1 — Matérias tóxicas	318	307	8 517 424	0.51	0.65	12.40
9 — Matérias e objetos perigosos diversos	215	213	2 935 389	0.45	0.74	8.40
5.1 — Matérias comburentes	98	77	1 913 713	0.46	0.71	3.80
4.1 — Sólidos inflamáveis	47	47	844 490	0.50	0.54	1.80
4.3 — Em contacto c/ água libertam gases inflamáveis	9	9	371 784	0.73	0.80	0.40
2.2 — Gases não inflamáveis, não tóxicos	8	6	127 477	0.56	0.66	0.30
1 — Explosivos	1	1	51 520	0.68	0.68	0
2.1 — Gases inflamáveis	1	1	161	0.60	0.60	0
5.2 — Peróxidos orgânicos	1	1	300	0.60	0.60	0
N/D — N/D	1	1	18 270	0.52	0.52	0




Figura 1 — Registos por classe ADR/RID (após normalização).

Leitura: a frequência é dominada pela classe 3 (líquidos inflamáveis, 43,8 %). Mas o maior risco médio por linha é da classe **4.3** (matérias que libertam gases inflamáveis em contacto com água) — única classe da amostra que combina prefixo X com incêndio. Exige atenção específica no plano de combate (evitar uso de água; usar pó químico ou espuma seca).

3.2 Viagens por dia da semana

Dia	Nº viagens	% do total
Segunda	17	17
Terça	21	21
Quarta	22	22
Quinta	16	16
Sexta	22	22
Sábado	2	2
Domingo	0	0




Figura 2 — Viagens com matérias perigosas por dia da semana. 98 % concentradas em dias úteis; fim de semana praticamente nulo.

3.3 Distribuição horária

100 % das partidas estão concentradas em quatro horas do dia (19h, 21h, 22h, 23h), com pico claro às 19h.

Hora	Nº viagens
19	64
21	2
22	32
23	2



Figura 3 — Distribuição horária da hora de partida (amostra).

3.4 Top 10 matérias — por frequência

Matéria	ONU	Classe	Kemler pior	Nº transp.	Qtd. (kg)	Raio evac. (m)	Risco
Tintas ou materias aparentadas as tintas	1263	3	33	358	4 260 675	800	0.69
Adesivos contendo um liquido inflamavel	1133	3	33	186	2 015 989	800	0.68
Aerossois	1950	2	26	171	2 738 463	800	0.72
Resina em solucao	1866	3	33	122	856 677	800	0.66
Diisocianato de toluileno	2078	6.1	60	118	2 452 339	800	0.54
Materia perigosa do ponto de vista do ambiente liquida n.s.a	3082	9	90	92	420 954	800	0.53
Liquido inflamavel n.s.a.	1993	3	33	89	566 933	800	0.66
Argon liquido refrigerado	1951	2	22	76	1 538 310	800	0.69
Materia perigosa do ponto de vista do ambiente solida n.s.a.	3077	9	90	60	372 609	800	0.54
Nitrobenzeno	1662	6.1	60	60	3 805 648	800	0.59




Figura 4 — Top 10 matérias mais transportadas (amostra normalizada).

3.5 Top 10 matérias — por risco (cenário menos favorável)

O **Top 10 por risco** é completamente diferente do **Top 10 por frequência**. Materiais raros mas de pior caso (Fosforeto de alumínio com Kemler **X462**, Etildiclorossilano **X338** — ambos classe 4.3) e gases liquefeitos sob pressão (Metilacetileno + propadieno, raio de evacuação de 1 600 m) saltam para o topo.

Matéria	ONU	Classe	Kemler pior	Nº transp.	Qtd. (kg)	Raio evac. (m)	Risco
Fosforeto de alumínio	1397	4.3	X462	1	5 930	800	0.80
Metilacetileno e propadieno em mistura estabilizada	1060	2	239	1	21 470	1 600	0.80
Acetato de vinilo estabilizado	1301	3	339	4	72 000	800	0.77
Etildiclorossilano	1183	4.3	X338	1	8 370	800	0.77
Alquifenóis líquidos	3145	8	88	7	84 000	800	0.76
Líquido inorgânico corrosivo ácido n.s.a.	3264	8	88	12	179 171	800	0.75
Líquido corrosivo n.s.a.	1760	8	88	37	393 002	800	0.75
Líquido corrosivo tóxico n.s.a.	2922	8	86	3	25 920	800	0.75
Aminas líquidas corrosivas n.s.a.	2735	8	88	10	68 702	800	0.75
Metanol	1230	3	336	2	22 010	800	0.74

Implicação operacional: estes 10 produtos devem ser listados nominalmente nos planos de emergência, com fichas de intervenção específicas e protocolos de combate dedicados (em especial os de classe 4.3, em que o uso de água é contraindicado).

4. Mapas de calor

4.1 Janela temporal — Dia × Hora




Figura 5 — Mapa de calor Dia × Hora. 100 % do risco temporal concentra-se em 4 horas/4 dias úteis.

Pico absoluto às 19h de quarta-feira/sexta e 22h de terça/quarta. O fim-de-semana é uma "ilha verde" — janela útil para inspeções, exercícios e manutenção do corredor ferroviário.

4.2 Severidade — Classe × N° Perigo (pior caso)




Figura 6 — Cruzamento entre Classe ADR/RID e 1º dígito do Kemler pior caso.

Permite verificar coerência interna (classe 3 deve ter Kemler a iniciar em 3) e detetar registos suspeitos (ex.: classe 8 com Kemler iniciado em 2 é provavelmente um erro de digitação a investigar).

4.3 Matriz de fluxo — Origem × Destino




Figura 7 — Mapa de calor de fluxos rota a rota.

A esmagadora maioria das viagens é **Leixões → Alcântara** (via Linha do Norte + Linha de Cintura). Existem secundárias Alcântara → Leixões e Alcântara ↔ Valença/Valença do Minho (exportação para Espanha).

4.4 Perfil de risco normalizado — Top 15 matérias




Figura 8 — Perfil de risco normalizado [0–1] para o Top 15 matérias × 5 indicadores.

Visualmente, uma linha completamente vermelha identificaria um produto perigoso em todos os indicadores — **não existe na amostra**: produtos de alta frequência (tintas) têm raio médio, produtos de risco máximo (fosforeto) têm baixa frequência. O trade-off frequência × severidade justifica o **planeamento dual** (exercícios para os frequentes, protocolos especiais para os severos).

4.5 Correlações entre indicadores




Figura 9 — Matriz de correlação de Pearson.

Correlação positiva entre RAO INCENDIO e RISCO EXPLOSAO (~0,7) confirma consistência interna. Correlação fraca entre QUANTIDADE e kemler_severidade (~0,1) confirma que **frequência/quantidade e severidade são dimensões ortogonais** — justifica os dois Top 10.

4.6 Mapa de impacto espacial — pior caso do Top 10




Figura 10 — Simulação 2D do impacto radial (grelha 20m × 20m, 3,6 km × 3,6 km centrada no ponto de acidente).

Três anéis concêntricos: **100 m** (evacuação imediata — interior em vermelho intenso), **500 m** (acidente grave — laranja/amarelo) e **800 m** (cenário de incêndio — verde claro a amarelo). A intensidade do risco cai por zonas (1.0 → 0.66 → 0.33 → 0). Sobreposto à planta urbana, identifica imediatamente os bairros a evacuar em cada zona.

4.7 Painel de impacto — Top 10 matérias

Mapa de impacto individual para cada uma das 10 matérias mais frequentes (raios em metros; ponto de acidente no centro). Permite comparar visualmente o alcance: a maioria converge para o raio de 800 m, mas o **Árgon líquido refrigerado** tem raio mínimo de 100 m (asfixia/BLEVE) e os **Aerossóis** têm raio máximo intermédio de 500 m.




Figura 11 — Painel de mapas de impacto para o Top 10 das matérias mais transportadas. Linha branca: raio mínimo (evacuação imediata). Linha amarela: raio máximo (acidente grave). Linha vermelha: raio de incêndio (pior caso). Estrela preta: ponto de acidente.

5. Corredor Parque das Nações ↔ Alcântara

5.1 Modelo de exposição por estação

Para as 10 estações da Linha de Cintura/Norte entre Parque das Nações e Alcântara, foi calculada uma medida de risco potencial:

$$\text{risco_estacao(matéria)} = \text{risco_indice_max} \cdot (\text{raio_evac} / 800) \cdot \text{densidade_urbana}$$

A `densidade_urbana` é um proxy manual (0,55–1,00) baseado no tecido urbano em redor de cada estação.
Carece de calibração com dados de cadastro / população real (BUE Lisboa, BGRI 2021).




Figura 12 — Mapa de calor de risco potencial: estações × Top 10 matérias.

5.2 Ranking das estações

Estação	Risco total
Entrecampos	6.29
Roma–Areeiro	5.98
Sete Rios	5.98
Oriente (Parque das Nações)	5.35
Campolide	5.35
Olaias	5.03
Alcântara-Terra	5.03
Chelas	4.40
Marvila	3.77
Braço de Prata	3.46




Figura 13 — Ranking das 10 estações do corredor por risco potencial.

Prioridade operacional: Entrecampos, Roma–Areeiro e Sete Rios devem ter postos de comando avançado pré-definidos e rotas de evacuação modeladas com prioridade.

5.3 Corredor de evacuação proposto

Cenário	Buffer ao eixo (m)	Justificação
Evacuação imediata	100	Máximo do RAI0 MINIMO no Top 10
Evacuação alargada	500	Máximo do RAI0 MAXIMO no Top 10
Cenário incêndio (pior caso Top 10)	800	RAIO INCENDIO adotado por todas as 10 matérias
Cenário extremo (pior matéria da amostra)	1 600	Isobutano (ONU 1969) — BLEVE de gás liquefeito

O **valor de planeamento** para a Linha de Cintura deve ser **800 m de cada lado do eixo ferroviário**, com aumento excecional para **1 600 m** quando o comboio transporta gases liquefeitos sob pressão (classe 2, ONU 1969 e 1060).

6. Conclusões e recomendações

1. Qualidade dos dados precisa de governance

81 % das linhas tinham o N° Perigo na coluna CLASSE — sintoma de validação ausente na introdução. Recomenda-se introduzir validação por lista pendente contra a lista RID na origem dos registos.

2. Janela de risco estreita e previsível

98 % das viagens em dias úteis, 19h–23h. Permite organizar escalas dedicadas de prontidão noturna no corredor; libera o fim-de-semana para exercícios.

3. Dois Top 10 distintos — frequência e severidade

Exige dois eixos de planeamento: (a) treino sistemático para os 10 mais frequentes (tintas, adesivos, aerossóis...); (b) protocolos nominais e fichas de intervenção para os 10 de risco máximo (Fosforeto de alumínio, Etildiclorossilano, Metilacetileno+propadieno).

4. Corredor de 800 m como buffer padrão; 1 600 m em cenário extremo

Sobrepor estas faixas ao GeoJSON da Rede Ferroviária do SMPC (não fornecido nesta amostra) isola os quarteirões a evacuar e os candidatos a zonas de apoio.

5. Estações críticas: Entrecampos, Roma–Areeiro, Sete Rios

Devem ter planos específicos por estação com rotas de evacuação, hospitais e escolas pré-mapeadas e zonas de apoio fora do raio de 800 m.

6. Próximos passos sugeridos

(i) Cruzar o buffer de 800/1 600 m com o cadastro BUE de Lisboa para quantificar população exposta. (ii) Calibrar a simulação 2D com modelo ALOHA/CAMEO usando as quantidades médias por matéria. (iii) Substituir o proxy de densidade urbana por dados reais de população residente + flutuante (BGRI 2021/DGT).

Anexo — Ficheiros gerados

Toda a análise é reproduzível executando `python3 analise/desafio.py` seguido de `python3 analise/gerar_pdf.py`.

Ficheiro	Descrição
<code>analise/desafio.py</code>	Pipeline completo: carregamento, limpeza, parser Kemler, índice de risco, gráficos.
<code>analise/gerar_pdf.py</code>	Conversor que gera este PDF a partir dos CSVs e PNGs.
<code>analise/RELATORIO.md</code>	Relatório em Markdown (idêntico em conteúdo a este PDF).
<code>analise/Relatorio_Tecnico.pdf</code>	Este relatório técnico em PDF.
<code>analise/00_resumo.csv</code>	Indicadores resumo (top do sumário executivo).
<code>analise/02_por_classe.csv</code>	Distribuição por classe ADR/RID normalizada.
<code>analise/03a_por_dia_semana.csv</code>	Distribuição de viagens por dia da semana.
<code>analise/03b_por_hora.csv</code>	Distribuição horária de viagens.
<code>analise/04_top10_materias.csv</code>	Top 10 matérias por frequência.
<code>analise/04b_top10_risco.csv</code>	Top 10 matérias por índice de risco composto.
<code>analise/06_risco_corredor_estacoes.csv</code>	Risco potencial por estação × matéria.
<code>analise/06b_risco_total_estacao.csv</code>	Risco total por estação (soma do Top 10).
<code>analise/h1_dia_hora.csv</code>	Matriz Dia × Hora (mapa de calor h1).
<code>analise/h2_classe_perigo.csv</code>	Matriz Classe × dígito Kemler (mapa de calor h2).
<code>analise/h3_origem_destino.csv</code>	Matriz Origem × Destino (mapa de calor h3).
<code>analise/clean/materias_clean.csv</code>	Registo de matérias com colunas auditáveis após limpeza.
<code>analise/clean/transportes_clean.csv</code>	Registo de viagens normalizado.
<code>analise/figuras/g1..g4 (4 PNG)</code>	Gráficos clássicos: classes, dias, hora, top 10.
<code>analise/figuras/h1..h9 (9 PNG)</code>	Mapas de calor: temporal, severidade, fluxo, perfil, correlações, impacto, painel, corredor, ranking.